Análisis de Caso

Disponibilidad de contenidos de aplicaciones en cloud

Eva Durán

alkemy

Análisis de Caso

Actividad evaluativa L6: *Disponibilidad de contenidos de aplicaciones en cloud*

Situación inicial 📍

La empresa **MediaStream** es una plataforma de contenidos multimedia que permite a usuarios de todo el mundo acceder a videos, imágenes y archivos informativos. Actualmente, MediaStream enfrenta problemas de latencia, caídas de servicio en momentos de alta demanda y quejas de usuarios que no pueden acceder a los contenidos desde ciertas regiones.

El equipo técnico ha identificado que la infraestructura actual no está diseñada para soportar picos de tráfico y no cuenta con mecanismos adecuados de distribución y disponibilidad de contenidos. La dirección de MediaStream ha solicitado el rediseño de su arquitectura para garantizar la disponibilidad continua de los contenidos, minimizar la latencia y mejorar la experiencia del usuario a nivel global.

Descripción del Caso 🔍

Eres un arquitecto cloud consultor contratado por MediaStream. Tu misión es diseñar e implementar una arquitectura robusta que garantice la alta disponibilidad y distribución eficiente de los contenidos multimedia.

Además, deberás considerar la protección de los contenidos sensibles, el uso de redes de entrega de contenido (CDN), balanceadores de carga y estrategias de escalabilidad automática. El enfoque debe estar orientado a lograr una solución resiliente, segura y rentable.

Instrucciones 💡

1. **Análisis del escenario actual:**

   → Identifica los principales problemas que enfrenta la plataforma MediaStream.

   → Describe los riesgos que implica la falta de disponibilidad y distribución adecuada de los contenidos.

2. **Propuesta de arquitectura cloud:**

   → Diseña un esquema arquitectónico utilizando EC2 Auto Scaling, ELB, CloudFront y Route 53.
   → Incluye la opción de integrar Direct Connect para conectar la infraestructura local de MediaStream, justificando en qué casos sería recomendable.

3. **Protección de contenidos:**

   → Define qué tipo de contenidos sensibles deben ser protegidos.
   → Describe al menos 3 mecanismos de protección que incluirías en la arquitectura.

4. **Justificación técnica:**

   → Explica por qué seleccionaste cada uno de los servicios cloud utilizados.
   → Describe cómo la arquitectura propuesta mejora la disponibilidad, escalabilidad y seguridad.

5. **Análisis de costos y rendimiento:**

   → Describe brevemente los aspectos que deben ser considerados para mantener un equilibrio entre costos y rendimiento en la arquitectura diseñada.

Entregables 📬

Al finalizar este análisis de caso, el participante deberá entregar:

✅ Un informe escrito que incluya:

- Análisis de los problemas y riesgos del escenario actual.
- Diagrama de la arquitectura propuesta.
- Explicación detallada de cada componente de la arquitectura.
- Estrategias de protección de contenido.
- Justificación de las decisiones técnicas.
- Reflexión sobre los costos y el rendimiento de la solución.

➕**Opcional**: Archivo del diagrama editable (draw.io, Lucidchart, Visio u otra herramienta).

DESARROLLO 📄

1. Análisis del escenario actual

Principales problemas identificados

1) Latencia elevada y variable a nivel global:

Las aplicaciones de entrega de contenidos requieren baja latencia y distribución geográfica del contenido, sin una arquitectura preparada para ello (caché en Edge locations y rutas eficientes), aumentan los tiempos de carga y la experiencia del usuario se ve afectada.

2) Caídas en picos de demanda (falta de elasticidad y distribución):

Cuando no se cuenta con escalado automático de cómputo y balanceo de cargo, los picos saturan el "origen" del contenido y provocan baja en la disponibilidad.

3) Ausencia o uso limitado de una CDN:

Sin una CDN que almacene en caché los objetos cerca del usuario, todas las solicitudes golpean al "origen", elevando latencia y costos, y reduciendo la resiliencia del sistema. Las CDN actúan como primera línea de entrega y descargan trabajo del backend.

4) Gestión de tráfico global insuficiente:

Sin una estrategia de Sistema de Nombres de Dominio (Domain Name System, DNS) con enrutamiento geográfico, es difícil dirigir a cada usuario hacia el punto más cercano o disponible, incrementando latencia y fallos percibidos.

5) Contenidos sensibles sin controles finos de acceso:

Una plataforma multimedia suele contener materiales licenciados o protegidos. Sin políticas de clasificación y acceso, y sin mecanismos como direcciones URL firmadas, el riesgo de exposición aumenta.

6) Monitoreo y observabilidad limitados:

La falta de telemetría y de mecanismos de recuperación ante fallos complica detectar cuellos de botella y anticipar incidentes. Es recomendable monitorear y registrar para proteger la continuidad y seguridad.

Riesgos por falta de disponibilidad y distribución adecuada

1) Riesgo operativo:

Interrupciones del servicio ante fallas de zona o picos de tráfico. Sin un balanceo multi-zona y caché, cualquier componente crítico se vuelve un

único punto de fallo.

2) Riesgo de experiencia de usuario:

Tiempos de carga altos, reproducciones interrumpidas o poco fluidas y errores intermitentes, con impacto directo en retención y conversión. Las arquitecturas de contenidos deben minimizar la latencia vía caché en Edge Locations, colocar copias de los contenidos en servidores distribuidos en puntos cercanos a los usuarios finales, como Amazon CloudFront) y rutas eficientes, es decir, aprovechar la red global de la nube para que el tráfico siga el camino más corto y confiable hacia el destino.

3) Riesgo de cumplimiento y licenciamiento:

Sin controles de acceso granulares (por ejemplo, URL firmadas), el contenido licenciado puede filtrarse o consumirse fuera de las condiciones contractuales.

4) Riesgo de costo:

Servir todo desde el origen (sin CDN), incrementa la transferencia de datos y uso de cómputo. Una CDN bien configurada reduce el tráfico al origen y optimiza el gasto.

5) Riesgo de seguridad y de red:

Al depender solo de internet pública y carecer de segmentación y cifrado consistentes, aumentan superficies de ataque y variabilidad de rendimiento. En escenarios híbridos, conexiones privadas dedicadas son clave.

2. Propuesta de arquitectura cloud

La siguiente propuesta considera principios de alta disponibilidad, baja latencia y escalabilidad automática.

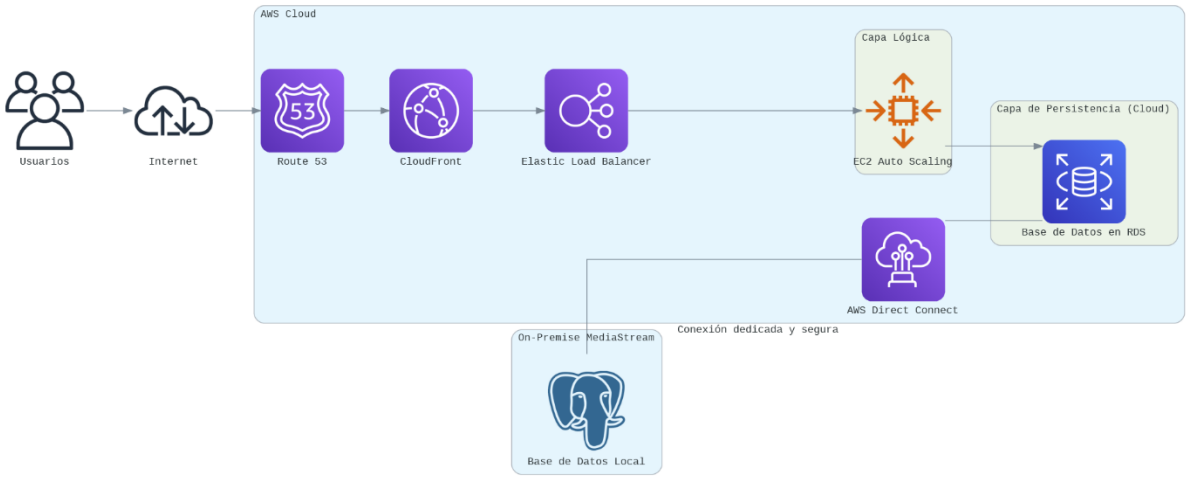

Figura 1. Diagrama de propuesta de arquitectura cloud para MediaStream.

Componentes principales de la arquitectura en AWS

1. **Amazon Route 53 (gestión de DNS global)**
    - Dirige el tráfico de usuarios hacia la infraestructura de MediaStream.
    - Garantiza que cada usuario acceda al punto de acceso más cercano y disponible.

2. **Amazon CloudFront (CDN – Content Delivery Network)**
    - Distribuye el contenido multimedia (videos, imágenes, archivos) en cachés ubicados en "edge locations" alrededor del mundo.
    - Reduce la latencia, al entregar el contenido desde el servidor más cercano al usuario.
    - Protege el origen, ya que los usuarios consumen el contenido desde Edge Locations y no saturan los servidores principales.

3. **Elastic Load Balancer (ELB – Balanceador de carga elástico)**
    - Recibe el tráfico que llega desde CloudFront.
    - Distribuye las solicitudes de manera uniforme entre múltiples instancias de aplicación (EC2).
    - Asegura disponibilidad: si una instancia falla, el balanceador dirige el tráfico hacia las instancias sanas.

4. **Amazon EC2 con Auto Scaling (Cómputo elástico)**
    - Servidores virtuales que alojan la aplicación de MediaStream.
    - El *Auto Scaling Group* agrega o elimina instancias automáticamente según la demanda (escalado horizontal).
    - Esto permite absorber picos de tráfico sin interrupciones, evitando costos por sobreaprovisionamiento en horarios de baja carga.

5. **AWS Direct Connect (conexión dedicada con on-premises)**
    - Se recomienda en caso de que MediaStream aún mantenga infraestructura local on-premise (bases de datos heredadas, sistemas internos).
    - Beneficios:
        - Conexión privada y dedicada (menor latencia que la Internet pública).
        - Mayor seguridad y estabilidad en la transmisión de datos.
        - Recomendable si MediaStream transfiere grandes volúmenes de datos sensibles entre su data center y AWS.
        -

6. **Amazon RDS**: gestión de alta disponibilidad multi-AZ, backups automáticos y cifrado nativo, reduciendo carga operativa.

Flujo de la arquitectura

1. Capa cliente: Los usuarios globales consultan la dirección del servicio en Route 53 (acceden desde internet).
2. El tráfico es dirigido al CloudFront Edge Location más cercano.
3. Si el contenido no está en caché, CloudFront lo solicita al origen, pasando primero por el ELB.
4. El ELB distribuye la solicitud a una de las instancias EC2 en Auto Scaling (en capa Lógica).
5. Las instancias procesan la solicitud (por ejemplo, autenticar usuario o entregar metadatos) y responden.
6. El contenido se almacena en el CloudFront cache, para que futuras solicitudes sean atendidas desde Edge locations.
7. Capa de Persistenia: base de datos en AWS RDS, con opción de mantener parte en on-premise. En este caso, en que MediaStream requiera integrar infraestructura local, se establece un canal seguro y estable vía Direct Connect.

Finalmente, la arquitectura propuesta para MediaStream se organiza en tres capas: cliente, lógica y persistencia, diferenciando entre los servicios en la nube de AWS y la infraestructura on-premise. Los usuarios acceden a través de Internet, siendo gestionados inicialmente por Route 53 para la resolución de nombres y CloudFront como CDN para optimizar la distribución global de contenidos. Posteriormente, un Elastic Load Balancer distribuye el tráfico hacia la capa lógica, compuesta por instancias bajo un esquema de Auto Scaling, garantizando elasticidad y alta disponibilidad. La capa de persistencia se apoya en una base de datos en RDS, que puede complementarse con la base de datos local de MediaStream. En este punto, la integración de AWS Direct Connect resulta estratégica, ya que permite establecer una conexión dedicada, segura y de baja latencia entre la infraestructura on-premise y la nube, habilitando un modelo híbrido que combina la flexibilidad del cloud con el control de los sistemas internos de la organización.

Si bien el diagrama arquitectónico se centra en los componentes principales de distribución y cómputo, es importante considerar la integración de servicios adicionales que fortalecen la seguridad y la resiliencia. Por un lado, AWS Identity and Access Management (IAM) permite definir con precisión qué servicios, roles o usuarios pueden acceder a los recursos internos de la arquitectura, aplicando el principio de mínimo privilegio. En complemento, Amazon Cognito ofrece la gestión de identidad y autenticación de usuarios finales, facilitando el control de acceso a contenidos premium o bajo suscripción. Además, aunque no estén representadas en el diagrama, la arquitectura propuesta debe desplegarse en múltiples Zonas de Disponibilidad (Availability Zones) dentro de cada región de AWS. Este

diseño distribuido asegura que, en caso de fallo de un centro de datos completo, las cargas de trabajo se mantengan activas en otras zonas, mejorando la disponibilidad y resiliencia global del sistema.

3. Protección de contenidos

Contenidos sensibles a proteger en MediaStream

En una plataforma multimedia como MediaStream, los contenidos sensibles que requieren medidas específicas de seguridad incluyen:

1) Contenidos audiovisuales licenciados: películas, series, conciertos, transmisiones en vivo. Su distribución está regulada por contratos de licenciamiento y no pueden ser accesibles libremente.
2) Contenidos exclusivos o premium: archivos bajo suscripción o pago por evento. Deben restringirse a usuarios autenticados con permisos vigentes.
3) Metadatos de los contenidos: información sobre derechos de autor, acuerdos de distribución, datos de usuarios que consumen contenidos. Son igualmente sensibles, pues revelan patrones de consumo y acuerdos comerciales.

Mecanismos de protección propuestos

1) URLs firmadas y Cookies firmadas en Amazon CloudFront

Permiten que solo los usuarios autorizados accedan a un objeto específico (video, imagen, archivo). Se genera un enlace temporal con fecha de expiración y restricciones (IP, región). Esto protege contra accesos no autorizados y redistribución ilegal de enlaces.

2) Cifrado de extremo a extremo

En tránsito: usar HTTPS/TLS en todas las comunicaciones entre clientes, CloudFront, Balanceadores y EC2.

En reposo: habilitar cifrado en Amazon S3, Amazon RDS y cualquier almacenamiento persistente.

Esto garantiza que aun si los datos son interceptados o extraídos, no puedan ser leídos sin la clave.

3) Digital Rights Management (DRM) y control de licencias

Implementar un sistema de gestión de derechos digitales que limite cómo se consumen los contenidos (por ejemplo, Widevine, PlayReady, FairPlay). Evita que los usuarios descarguen, copien o distribuyan contenidos protegidos.

4) Integración con AWS Identity Access Management (IAM) y Amazon Cognito

IAM asegura que solo los servicios autorizados accedan a los contenidos en AWS. Cognito permite autenticar usuarios finales y asignar permisos según el plan contratado.

La plataforma MediaStream debe proteger especialmente los contenidos audiovisuales licenciados, los materiales exclusivos bajo suscripción y los metadatos asociados, ya que representan activos estratégicos y de alto valor comercial. Para asegurar su resguardo, la arquitectura incorpora múltiples mecanismos de protección. En primer lugar, se utilizan URLs firmadas y cookies firmadas en CloudFront, limitando el acceso únicamente a usuarios autorizados y bajo condiciones predefinidas. En segundo lugar, se aplica cifrado de extremo a extremo, tanto en tránsito mediante HTTPS/TLS como en reposo a través del cifrado nativo de los servicios de almacenamiento de AWS. Finalmente, se recomienda implementar Digital Rights Management (DRM) para reforzar el control de licencias y evitar la copia o redistribución no autorizada de los contenidos. Estas medidas en conjunto garantizan la seguridad, cumplimiento normativo y la preservación del valor comercial de los recursos multimedia de MediaStream.

4. Justificación técnica

¿Cómo la arquitectura mejora la disponibilidad?

- **Eliminación de puntos únicos de fallo**: Route 53 permite monitorear la salud de los recursos mediante "health checks" (verificaciones de estado). ELB opera sobre múltiples Zonas de Disponibildad, aumentando la disponibilidad del sistema. EC2 Auto Scaling repone instancias caídas automáticamente y puede distribuirlas por subredes en distintas zonas.
- **Descarga de origen y resiliencia en el *edge*:** CloudFront sirve desde caché. Si el origen sufre degradación temporal, los objetos ya cacheados siguen disponibles durante su tiempo de vida.
- **Conectividad Híbrida robusta**: Direct Connect ofrece un camino alternativo a Internet pública para procesos críticos on-premise y AWS.

¿Cómo la arquitectura mejora la escalabilidad?

- **Escalado horizontal automáti**co: EC2 Auto Scaling crece o reduce instancias por métricas (CPU, conexiones, latencia, solicitudes por segundo) o por programaciones. Amortigua picos impredecibles de demanda.
- **Distribución eficiente del tráfico**: ELB balancea por grupos de destino y mantiene sesiones (si lo configuras), lo que evita saturar nodos individuales.
- **Red global de Edge Locations**: CloudFront replica y sirve contenido desde cientos de ubicaciones. Cada Edge Location atiende su propia demanda local sin saturar el backend.
- **Dirección inteligente del tráfico global**: Route 53 con políticas de "latency-based routing" y "geolocation" reparten la carga hacia el mejor punto de entrada en cada momento.

¿Cómo la arquitectura mejora la seguridad?

- **Cifrado extremo a extremo:** cifrado en tránsito TLS (Transport Layer Security) entre cliente ↔ CloudFront ↔ ELB ↔ instancias. Cifrado en reposo en RDS (y en almacenamiento de objetos).
- **Control de acceso al contenido**: CloudFront con URLs firmadas y cookies firmadas restringe quién puede descargar y por cuánto tiempo.
- **Segmentación y principio de mínimo privilegio**: Grupos de seguridad y Listas de Control de Acceso a nivel de red. AWS Identity and Access Management (IAM) para definir qué servicio/rol puede leer cada origen.
- **Superficie de exposición reducida para datos híbridos**: Direct Connect evita exponer flujos sensibles a Internet pública. Combinado con políticas de firewall on-premise y en la nube, se reducen riesgos de intercepción.

5. Análisis de costos y rendimiento

1) Uso eficiente del caché en Amazon CloudFront

- Cada vez que el contenido es servido desde el edge en lugar del origen, se reducen costos de transferencia desde instancias y bases de datos.
- Un tiempo de vida adecuado evita solicitar constantemente el contenido al backend y optimiza la latencia.

2) Elasticidad con EC2 Auto Scaling

- El escalado automático permite pagar solo por la capacidad necesaria en cada momento.
- Evita el sobreaprovisionamiento en horarios de baja demanda y garantiza disponibilidad en picos de tráfico sin comprometer la experiencia de usuario.

3) Optimización en el uso de instancias

- Seleccionar tipos de instancias adecuados según la carga (por ejemplo, instancias optimizadas para cómputo o red).
- Posibilidad de usar instancias reservadas o savings plans para cargas constantes, combinadas con instancias bajo demanda para cargas variables.

4) Balance entre base de datos en la nube y on-premise

- Mantener una base de datos principal en Amazon RDS con backups automáticos implica un costo, pero reduce riesgos operativos.
- Si MediaStream mantiene una parte on-premise conectada por Direct Connect, debe evaluar el costo de la conexión dedicada versus los beneficios de latencia y seguridad.

5) Servicios gestionados vs autogestionados

- Servicios como RDS, CloudFront y ELB implican costos adicionales frente a manejar todo con instancias EC2, pero reducen la carga operativa y mejoran la confiabilidad.

La arquitectura propuesta busca un equilibrio entre rendimiento óptimo para el usuario final y eficiencia en los costos operativos. Al integrar CloudFront, se reducen significativamente la latencia y el tráfico hacia el backend, lo que se traduce en menor gasto en cómputo y transferencia de datos desde el origen. El escalado automático de EC2 asegura que MediaStream solo pague por la capacidad que realmente utiliza, evitando costos innecesarios en periodos de baja demanda. Por su parte, el uso de servicios gestionados como RDS y ELB incrementa el costo directo frente a soluciones autogestionadas, pero aporta un valor superior en resiliencia, seguridad y reducción de carga operativa. En escenarios híbridos, Direct Connect implica una inversión adicional, pero puede justificarse para cargas críticas que requieren baja latencia y seguridad reforzada. En conjunto, esta solución prioriza la calidad de la experiencia del usuario a nivel global, manteniendo un modelo de costos flexible y ajustado al consumo real de los recursos en la nube.

6. Referencias

https://awsfundamentals.com/blog/aws-edge-locations
https://aws.amazon.com/es/pm/cognito/
https://aws.amazon.com/es/directconnect/
https://aws.amazon.com/es/route53/
https://aws.amazon.com/es/iam/
https://aws.amazon.com/es/ec2/autoscaling/